

SUBE AMBA: patrones de uso del transporte público

Valentina Barroso y Karen Del Pino

Table of contents

SECCIÓN 1- Importar y describir el dataset	1
Chunk 1: Librerías	1
Chunk 2:	2
SECCIÓN 2- “Clasificación de variables”	3
Chunk 3:	3
Sección 3- “Medidas de posición”	3
Chunk 4:	3
Chunk 5:	4
SECCIÓN 4- “Histogramas y boxplots”	5
SECCIÓN 5- Interpretación del histograma.	10
Conclusiones final.	12

SECCIÓN 1- Importar y describir el dataset

Chunk 1: Librerías

*Cargamos las herramientas de R que se utilizan en todo el reporte (lectura de csv, manipulación de datos, gráficos).

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
```

```
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

Chunk 2:

*Traemos el archivo csv a R como una tabla, muestra su estructura (filas, columnas, tipos de dato) y un resumen estadístico rápido de cada columna.

```
datos <- read_csv("datos/dataset_sube.csv")
```

```
Rows: 2367 Columns: 6
-- Column specification -----
Delimiter: ","
dbl (6): colectivo_amba, subte_amba, tren_amba, anio, mes, dia_semana

i Use `spec()` to retrieve the full column specification for this data.
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
glimpse(datos)
```

```
Rows: 2,367
Columns: 6
$ colectivo_amba <dbl> 774164, 2941242, 3189868, 2231075, 1381083, 3128048, 31~
$ subte_amba    <dbl> 72180, 511136, 536129, 232491, 127770, 543433, 553337, ~
$ tren_amba     <dbl> 112267, 719232, 779038, 460891, 203694, 771588, 773865,~
$ anio          <dbl> 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2~
$ mes           <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ dia_semana    <dbl> 2, 3, 4, 5, 6, 0, 1, 2, 3, 4, 5, 6, 0, 1, 2, 3, 4, 5, 6~
```

```
summary(datos)
```

colectivo_amba	subte_amba	tren_amba	anio
Min. : 229813	Min. : 1	Min. : 90	Min. : 2020
1st Qu.: 1465325	1st Qu.: 116388	1st Qu.: 202264	1st Qu.: 2021
Median : 2560304	Median : 253353	Median : 481003	Median : 2023
Mean : 2510098	Mean : 262609	Mean : 454165	Mean : 2023
3rd Qu.: 3586697	3rd Qu.: 408653	3rd Qu.: 679251	3rd Qu.: 2025

Max.	:4114665	Max.	:706371	Max.	:900832	Max.	:2026
	mes		dia_semana				
Min.	: 1.000	Min.	:0.000				
1st Qu.:	3.000	1st Qu.:	1.000				
Median	: 6.000	Median	:3.000				
Mean	: 6.366	Mean	:3.005				
3rd Qu.:	9.000	3rd Qu.:	5.000				
Max.	:12.000	Max.	:6.000				

SECCIÓN 2- “Clasificación de variables”

Chunk 3:

*Conviertimos el número de día (0, 1, 2...) en su nombre real (“Lunes”, “Martes”...), para que las tablas y gráficos sean más fáciles de leer en vez de mostrar números crípticos.

*Numéricas: colectivo_amba, subte_amba, tren_amba

*Categoría: anio, mes, dia_semana.

```
dias <- c("Lunes", "Martes", "Miércoles", "Jueves", "Viernes", "Sábado", "Domingo")
datos <- datos %>%
  mutate(dia_semana_lbl = factor(dias[dia_semana + 1], levels = dias))
```

Sección 3- “Medidas de posición”

Chunk 4:

*Calculamos el promedio y la medida de usuarios diarios, por cada medio de transporte.

```
datos %>%
  summarise(
    media_colectivo = mean(colectivo_amba, na.rm = TRUE),
    mediana_colectivo = median(colectivo_amba, na.rm = TRUE),
    media_subte = mean(subte_amba, na.rm = TRUE),
    mediana_subte = median(subte_amba, na.rm = TRUE),
    media_tren = mean(tren_amba, na.rm = TRUE),
    mediana_tren = median(tren_amba, na.rm = TRUE)
  )
```

```
# A tibble: 1 x 6
  media_colectivo mediana_colectivo media_subte mediana_subte media_tren
      <dbl>           <dbl>           <dbl>           <dbl>           <dbl>
1    2510098.         2560304         262609.         253353         454165.
# i 1 more variable: mediana_tren <dbl>
```

Chunk 5:

*Calcula el valor que más se repite en cada variable.

```
moda <- function(x) {
  ux <- unique(na.omit(x))
  ux[which.max(tabulate(match(x, ux)))]
}

moda(datos$colectivo_amba)
```

```
[1] 3710910
```

```
moda(datos$subte_amba)
```

```
[1] 329915
```

```
moda(datos$tren_amba)
```

```
[1] 114315
```

Chunk 6:

*Calculamos los cuartiles (25%, 50%, 75%) y deciles (de a 10%), que muestran cómo se reparten los datos, no solo su centro.

```
quantile(datos$colectivo_amba, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```
      25%      50%      75%
1465325 2560304 3586697
```

```
quantile(datos$colectivo_amba, probs = seq(0, 1, 0.1), na.rm = TRUE)
```

```

      0%      10%      20%      30%      40%      50%      60%      70%      80%      90%
229813 1039074 1336933 1809395 2208098 2560304 3059373 3462362 3675089 3810253
      100%
4114665

```

```
quantile(datos$subte_amba, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```

      25%      50%      75%
116388.0 253353.0 408652.5

```

```
quantile(datos$subte_amba, probs = seq(0, 1, 0.1), na.rm = TRUE)
```

```

      0%      10%      20%      30%      40%      50%      60%      70%
1.0  44559.4  95610.0 131630.4 174456.0 253353.0 309190.4 356455.4
      80%      90%     100%
449343.4 513645.8 706371.0

```

```
quantile(datos$tren_amba, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```

      25%      50%      75%
202263.5 481003.0 679250.5

```

```
quantile(datos$tren_amba, probs = seq(0, 1, 0.1), na.rm = TRUE)
```

```

      0%      10%      20%      30%      40%      50%      60%      70%
90.0 111815.8 162408.6 293915.8 385308.0 481003.0 598803.4 651993.8
      80%      90%     100%
700060.6 742715.0 900832.0


```

SECCIÓN 4- “Histogramas y boxplots”


Chunk 7:

*Generamos el histograma (cuántos días tuvieron cierta cantidad de usuarios) y el boxplot (mediana, rango típico y outliers) de **colectivo**.

```
ggplot(datos, aes(x = colectivo_amba)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  labs(title = "Histograma - Usuarios de colectivo", x = "Usuarios", y = "Frecuencia")
```



```
ggplot(datos, aes(y = colectivo_amba)) +
  geom_boxplot(fill = "lightblue") +
  labs(title = "Boxplot - Usuarios de colectivo")
```




Chunk 8:

*Lo mismo, para **subte**.


```
ggplot(datos, aes(x = subte_amba)) +  
  geom_histogram(bins = 30, fill = "darkorange", color = "white") +  
  labs(title = "Histograma - Usuarios de subte", x = "Usuarios", y = "Frecuencia")
```

Histograma – Usuarios de subte



```
ggplot(datos, aes(y = subte_amba)) +  
  geom_boxplot(fill = "moccasin") +  
  labs(title = "Boxplot - Usuarios de subte")
```


Boxplot – Usuarios de subte




Chunk 9:

*Lo mismo, para **tren**.

```
ggplot(datos, aes(x = tren_amba)) +  
  geom_histogram(bins = 30, fill = "forestgreen", color = "white") +  
  labs(title = "Histograma - Usuarios de tren", x = "Usuarios", y = "Frecuencia")
```



```
ggplot(datos, aes(y = tren_amba)) +  
  geom_boxplot(fill = "palegreen") +  
  labs(title = "Boxplot - Usuarios de tren")
```



SECCIÓN 5- Interpretación del histograma.

Chunk 10:

*Calculamos qué tan ancho es cada intervalo del histograma (rango total dividido en 10 partes), para colectivo.

```
rango <- max(datos$colectivo_amba, na.rm = TRUE) - min(datos$colectivo_amba, na.rm = TRUE)
amplitud <- rango / 10
amplitud
```

```
[1] 388485.2
```

Chunk 11:

*Días que caen en cada intervalo (tabla de frecuencias) para colectivo, con frecuencia relativa, porcentual y acumulada.

```
datos %>%
  mutate(intervalo = cut(colectivo_amba, breaks = 10)) %>%
  count(intervalo) %>%
  mutate(
```

```
frec_relativa = n / sum(n),
frec_porcentual = round(frec_relativa * 100, 2),
frec_acumulada = cumsum(n)
)
```

A tibble: 10 x 5

	intervalo	n	frec_relativa	frec_porcentual	frec_acumulada
	<fct>	<int>	<dbl>	<dbl>	<int>
1	(2.26e+05,6.18e+05]	74	0.0313	3.13	74
2	(6.18e+05,1.01e+06]	151	0.0638	6.38	225
3	(1.01e+06,1.4e+06]	307	0.130	13.0	532
4	(1.4e+06,1.78e+06]	169	0.0714	7.14	701
5	(1.78e+06,2.17e+06]	217	0.0917	9.17	918
6	(2.17e+06,2.56e+06]	266	0.112	11.2	1184
7	(2.56e+06,2.95e+06]	184	0.0777	7.77	1368
8	(2.95e+06,3.34e+06]	215	0.0908	9.08	1583
9	(3.34e+06,3.73e+06]	396	0.167	16.7	1979
10	(3.73e+06,4.12e+06]	388	0.164	16.4	2367

Chunk 12:

*Lo mismo, para **subte**.

```
datos %>%
  mutate(intervalo = cut(subte_amba, breaks = 10)) %>%
  count(intervalo) %>%
  mutate(
    frec_relativa = n / sum(n),
    frec_porcentual = round(frec_relativa * 100, 2),
    frec_acumulada = cumsum(n)
  )
```

A tibble: 10 x 5

	intervalo	n	frec_relativa	frec_porcentual	frec_acumulada
	<fct>	<int>	<dbl>	<dbl>	<int>
1	(-705,7.06e+04]	336	0.142	14.2	336
2	(7.06e+04,1.41e+05]	442	0.187	18.7	778
3	(1.41e+05,2.12e+05]	251	0.106	10.6	1029
4	(2.12e+05,2.83e+05]	272	0.115	11.5	1301
5	(2.83e+05,3.53e+05]	347	0.147	14.7	1648
6	(3.53e+05,4.24e+05]	158	0.0668	6.68	1806

7	(4.24e+05,4.94e+05]	253	0.107	10.7	2059
8	(4.94e+05,5.65e+05]	275	0.116	11.6	2334
9	(5.65e+05,6.36e+05]	27	0.0114	1.14	2361
10	(6.36e+05,7.07e+05]	6	0.00253	0.25	2367

Chunk 13:

*Lo mismo, para **tren**.

```
datos %>%
  mutate(intervalo = cut(tren_amba, breaks = 10)) %>%
  count(intervalo) %>%
  mutate(
    frec_relativa = n / sum(n),
    frec_porcentual = round(frec_relativa * 100, 2),
    frec_acumulada = cumsum(n)
  )
```

A tibble: 10 x 5

	intervalo	n	frec_relativa	frec_porcentual	frec_acumulada
	<fct>	<int>	<dbl>	<dbl>	<int>
1	(-811,9.02e+04]	150	0.0634	6.34	150
2	(9.02e+04,1.8e+05]	391	0.165	16.5	541
3	(1.8e+05,2.7e+05]	140	0.0591	5.91	681
4	(2.7e+05,3.6e+05]	207	0.0875	8.75	888
5	(3.6e+05,4.5e+05]	233	0.0984	9.84	1121
6	(4.5e+05,5.41e+05]	153	0.0646	6.46	1274
7	(5.41e+05,6.31e+05]	280	0.118	11.8	1554
8	(6.31e+05,7.21e+05]	479	0.202	20.2	2033
9	(7.21e+05,8.11e+05]	309	0.131	13.0	2342
10	(8.11e+05,9.02e+05]	25	0.0106	1.06	2367

Conclusiones final.

El colectivo es el medio de transporte más usado en el AMBA, muy por encima de subte y tren. Los tres muestran un patrón semanal claro: los fines de semana (sobre todo los domingos) tienen bastante menos usuarios que los días hábiles.

Durante marzo-mayo de 2020, con el inicio de la pandemia, el uso cayó abruptamente, generando outliers marcados en los boxplots. A partir de 2021 el uso se fue recuperando hasta estabilizarse en niveles similares a los previos a la pandemia.

Por estos dos factores (ciclo semanal y pandemia), las tres variables presentan distribuciones con sesgo hacia la izquierda, en vez de una forma simétrica.