

SUBE AMBA: patrones de uso del transporte público

Valentina Barroso y Karen Del Pino

Table of contents

SECCIÓN 1- Importar y describir el dataset	1
Chunk 1: Librerías	1
Chunk 2:	2
SECCIÓN 2- “Clasificación de variables”	3
Chunk 3:	3
Sección 3- “Medidas de posición”	4
Chunk 4:	4
Chunk 5:	4
SECCIÓN 4- “Histogramas y boxplots”	6
SECCIÓN 5- Interpretación del histograma.	11
Conclusiones final.	13

SECCIÓN 1- Importar y describir el dataset

Chunk 1: Librerías

*Cargamos las herramientas de R que se utilizan en todo el reporte (lectura de csv, manipulación de datos, gráficos).

```
library(tidyverse)
```

```
-- Attaching core tidyverse packages ----- tidyverse 2.0.0 --
v dplyr      1.2.1      v readr      2.2.0
v forcats    1.0.1      v stringr    1.6.0
v ggplot2     4.0.3      v tibble     3.3.1
v lubridate  1.9.5      v tidyr      1.3.2
```

```
v purrr      1.2.2
-- Conflicts ----- tidyverse_conflicts() --
x dplyr::filter() masks stats::filter()
x dplyr::lag()    masks stats::lag()
i Use the conflicted package (<http://conflicted.r-lib.org/>) to force all conflicts to become
```

```
library(scales)
```

Adjuntando el paquete: 'scales'

The following object is masked from 'package:purrr':

```
discard
```

The following object is masked from 'package:readr':

```
col_factor
```

Chunk 2:

*Traemos el archivo csv a R como una tabla, muestra su estructura (filas, columnas, tipos de dato) y un resumen estadístico rápido de cada columna.

```
datos <- read_csv("datos/dataset_sube.csv")
```

```
Rows: 2386 Columns: 6
```

```
-- Column specification -----
```

```
Delimiter: ","
```

```
dbl (6): colectivo_amba, subte_amba, tren_amba, anio, mes, dia_semana
```

```
i Use `spec()` to retrieve the full column specification for this data.
```

```
i Specify the column types or set `show_col_types = FALSE` to quiet this message.
```

```
glimpse(datos)
```

```
Rows: 2,386
```

```
Columns: 6
```

```
$ colectivo_amba <dbl> 774164, 2941242, 3189868, 2231075, 1381083, 3128048, 31~
```

```
$ subte_amba <dbl> 72180, 511136, 536129, 232491, 127770, 543433, 553337, ~
```

```
$ tren_amba      <dbl> 112267, 719232, 779038, 460891, 203694, 771588, 773865,~
$ anio           <dbl> 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2020, 2~
$ mes            <dbl> 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 1~
$ dia_semana     <dbl> 2, 3, 4, 5, 6, 0, 1, 2, 3, 4, 5, 6, 0, 1, 2, 3, 4, 5, 6~
```

```
summary(datos)
```

colectivo_amba	subte_amba	tren_amba	anio
Min. : 229813	Min. : 1	Min. : 90	Min. : 2020
1st Qu.: 1466013	1st Qu.: 116853	1st Qu.: 203255	1st Qu.: 2021
Median : 2565082	Median : 254484	Median : 483368	Median : 2023
Mean : 2512723	Mean : 262465	Mean : 454357	Mean : 2023
3rd Qu.: 3584237	3rd Qu.: 406443	3rd Qu.: 678739	3rd Qu.: 2025
Max. : 4114665	Max. : 706371	Max. : 900832	Max. : 2026

mes	dia_semana
Min. : 1.000	Min. : 0.000
1st Qu.: 3.000	1st Qu.: 1.000
Median : 6.000	Median : 3.000
Mean : 6.385	Mean : 3.007
3rd Qu.: 9.000	3rd Qu.: 5.000
Max. : 12.000	Max. : 6.000

SECCIÓN 2- “Clasificación de variables”

Chunk 3:

*Conviertimos el número de día (0, 1, 2...) en su nombre real (“Lunes”, “Martes”...), para que las tablas y gráficos sean más fáciles de leer en vez de mostrar números crípticos.

*Numéricas: colectivo_amba, subte_amba, tren_amba

*Categoría: anio, mes, dia_semana.

```
dias <- c("Lunes", "Martes", "Miércoles", "Jueves", "Viernes", "Sábado", "Domingo")
datos <- datos %>%
  mutate(dia_semana_lbl = factor(dias[dia_semana + 1], levels = dias))
```

Sección 3- “Medidas de posición”

Chunk 4:

*Calculamos el promedio y la medida de usuarios diarios, por cada medio de transporte.

```
datos %>%
  summarise(
    media_colectivo = mean(colectivo_amba, na.rm = TRUE),
    mediana_colectivo = median(colectivo_amba, na.rm = TRUE),
    media_subte = mean(subte_amba, na.rm = TRUE),
    mediana_subte = median(subte_amba, na.rm = TRUE),
    media_tren = mean(tren_amba, na.rm = TRUE),
    mediana_tren = median(tren_amba, na.rm = TRUE)
  )

# A tibble: 1 x 6
  media_colectivo mediana_colectivo media_subte mediana_subte media_tren
      <dbl>           <dbl>           <dbl>           <dbl>           <dbl>
1      2512723.         2565082         262465.         254484         454357.
# i 1 more variable: mediana_tren <dbl>
```

Chunk 5:

*Calcula el valor que más se repite en cada variable.

```
moda <- function(x) {
  ux <- unique(na.omit(x))
  ux[which.max(tabulate(match(x, ux)))]
}

moda(datos$colectivo_amba)
```

```
[1] 3710910
```

```
moda(datos$subte_amba)
```

```
[1] 329915
```

```
moda(datos$tren_amba)
```

```
[1] 114315
```

Chunk 6:

*Calculamos los cuartiles (25%, 50%, 75%) y deciles (de a 10%), que muestran cómo se reparten los datos, no solo su centro.

```
quantile(datos$colectivo_amba, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```
      25%      50%      75%  
1466013 2565082 3584237
```

```
quantile(datos$colectivo_amba, probs = seq(0, 1, 0.1), na.rm = TRUE)
```

```
      0%      10%      20%      30%      40%      50%      60%      70%      80%      90%  
229813 1043033 1337867 1811094 2209124 2565082 3060866 3468144 3673159 3809041  
      100%  
4114665
```

```
quantile(datos$subte_amba, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```
      25%      50%      75%  
116853.0 254484.0 406443.2
```

```
quantile(datos$subte_amba, probs = seq(0, 1, 0.1), na.rm = TRUE)
```

```
      0%      10%      20%      30%      40%      50%      60%      70%  
1.0  44929.0  95770.0 131963.5 174510.0 254484.0 308988.0 354912.0  
      80%      90%     100%  
448272.0 512719.5 706371.0
```

```
quantile(datos$tren_amba, probs = c(0.25, 0.5, 0.75), na.rm = TRUE)
```

```
      25%      50%      75%  
203255.0 483368.0 678738.5
```

```
quantile(datos$tren_amba, probs = seq(0, 1, 0.1), na.rm = TRUE)
```

```

0%      10%      20%      30%      40%      50%      60%      70%
90.0 112412.0 163307.0 294810.0 385591.0 483368.0 599097.0 650139.5
80%      90%     100%
699566.0 741983.0 900832.0

```

SECCIÓN 4- “Histogramas y boxplots”


Chunk 7:

*Generamos el histograma (cuántos días tuvieron cierta cantidad de usuarios) y el boxplot (mediana, rango típico y outliers) de **colectivo**.


```

ggplot(datos, aes(x = colectivo_amba)) +
  geom_histogram(bins = 30, fill = "steelblue", color = "white") +
  # scale = 1e-6 divide el número por un millón, suffix = "M" le agrega la letra
  scale_x_continuous(labels = label_number(scale = 1e-6, suffix = "M")) +
  labs(title = "Histograma - Usuarios de colectivo", x = "Usuarios", y = "Frecuencia")

```



```
ggplot(datos, aes(y = colectivo_amba)) +
  geom_boxplot(fill = "lightblue") +
  scale_y_continuous(labels = label_number(scale = 1e-6, suffix = "M")) +
  labs(title = "Boxplot - Usuarios de colectivo")
```




Chunk 8:


*Lo mismo, para **subte**.

```
ggplot(datos, aes(x = subte_amba)) +
  geom_histogram(bins = 30, fill = "darkorange", color = "white") +
  scale_x_continuous(labels = label_number(scale = 1e-3, suffix = "K")) +
  labs(title = "Histograma - Usuarios de subte", x = "Usuarios", y = "Frecuencia")
```

Histograma – Usuarios de subte



```
ggplot(datos, aes(y = subte_amba)) +  
  geom_boxplot(fill = "moccasin") +  
  scale_y_continuous(labels = label_number(scale = 1e-3, suffix = "K")) +  
  labs(title = "Boxplot - Usuarios de subte")
```




Chunk 9:


*Lo mismo, para **tren**.

```
ggplot(datos, aes(x = tren_amba)) +  
  geom_histogram(bins = 30, fill = "forestgreen", color = "white") +  
  labs(title = "Histograma - Usuarios de tren", x = "Usuarios", y = "Frecuencia")
```

Histograma – Usuarios de tren



```
ggplot(datos, aes(y = tren_amba)) +  
  geom_boxplot(fill = "palegreen") +  
  scale_y_continuous(labels = label_number(scale = 1e-3, suffix = "K")) +  
  labs(title = "Boxplot - Usuarios de tren")
```



SECCIÓN 5- Interpretación del histograma.

Chunk 10:

*Calculamos qué tan ancho es cada intervalo del histograma (rango total dividido en 10 partes), para colectivo.

```
rango <- max(datos$colectivo_amba, na.rm = TRUE) - min(datos$colectivo_amba, na.rm = TRUE)
amplitud <- rango / 10
amplitud
```

```
[1] 388485.2
```

Chunk 11:

*Días que caen en cada intervalo (tabla de frecuencias) para colectivo, con frecuencia relativa, porcentual y acumulada.

```
datos %>%
  mutate(intervalo = cut(colectivo_amba, breaks = 10)) %>%
  count(intervalo) %>%
  mutate(
```

```
frec_relativa = n / sum(n),
frec_porcentual = round(frec_relativa * 100, 2),
frec_acumulada = cumsum(n)
)
```

A tibble: 10 x 5

	intervalo	n	frec_relativa	frec_porcentual	frec_acumulada
	<fct>	<int>	<dbl>	<dbl>	<int>
1	(2.26e+05,6.18e+05]	74	0.0310	3.1	74
2	(6.18e+05,1.01e+06]	151	0.0633	6.33	225
3	(1.01e+06,1.4e+06]	310	0.130	13.0	535
4	(1.4e+06,1.78e+06]	169	0.0708	7.08	704
5	(1.78e+06,2.17e+06]	220	0.0922	9.22	924
6	(2.17e+06,2.56e+06]	266	0.111	11.2	1190
7	(2.56e+06,2.95e+06]	186	0.0780	7.8	1376
8	(2.95e+06,3.34e+06]	216	0.0905	9.05	1592
9	(3.34e+06,3.73e+06]	406	0.170	17.0	1998
10	(3.73e+06,4.12e+06]	388	0.163	16.3	2386

Chunk 12:

*Lo mismo, para **subte**.

```
datos %>%
  mutate(intervalo = cut(subte_amba, breaks = 10)) %>%
  count(intervalo) %>%
  mutate(
    frec_relativa = n / sum(n),
    frec_porcentual = round(frec_relativa * 100, 2),
    frec_acumulada = cumsum(n)
  )
```

A tibble: 10 x 5

	intervalo	n	frec_relativa	frec_porcentual	frec_acumulada
	<fct>	<int>	<dbl>	<dbl>	<int>
1	(-705,7.06e+04]	336	0.141	14.1	336
2	(7.06e+04,1.41e+05]	446	0.187	18.7	782
3	(1.41e+05,2.12e+05]	253	0.106	10.6	1035
4	(2.12e+05,2.83e+05]	272	0.114	11.4	1307
5	(2.83e+05,3.53e+05]	360	0.151	15.1	1667
6	(3.53e+05,4.24e+05]	158	0.0662	6.62	1825

7	(4.24e+05,4.94e+05]	253	0.106	10.6	2078
8	(4.94e+05,5.65e+05]	275	0.115	11.5	2353
9	(5.65e+05,6.36e+05]	27	0.0113	1.13	2380
10	(6.36e+05,7.07e+05]	6	0.00251	0.25	2386

Chunk 13:

*Lo mismo, para **tren**.

```
datos %>%
  mutate(intervalo = cut(tren_amba, breaks = 10)) %>%
  count(intervalo) %>%
  mutate(
    frec_relativa = n / sum(n),
    frec_porcentual = round(frec_relativa * 100, 2),
    frec_acumulada = cumsum(n)
  )
```

A tibble: 10 x 5

	intervalo	n	frec_relativa	frec_porcentual	frec_acumulada
	<fct>	<int>	<dbl>	<dbl>	<int>
1	(-811,9.02e+04]	150	0.0629	6.29	150
2	(9.02e+04,1.8e+05]	394	0.165	16.5	544
3	(1.8e+05,2.7e+05]	140	0.0587	5.87	684
4	(2.7e+05,3.6e+05]	210	0.0880	8.8	894
5	(3.6e+05,4.5e+05]	232	0.0972	9.72	1126
6	(4.5e+05,5.41e+05]	155	0.0650	6.5	1281
7	(5.41e+05,6.31e+05]	292	0.122	12.2	1573
8	(6.31e+05,7.21e+05]	479	0.201	20.1	2052
9	(7.21e+05,8.11e+05]	309	0.130	13.0	2361
10	(8.11e+05,9.02e+05]	25	0.0105	1.05	2386

Conclusiones final.

El colectivo es el medio de transporte más usado en el AMBA, muy por encima de subte y tren. Los tres muestran un patrón semanal claro: los fines de semana (sobre todo los domingos) tienen bastante menos usuarios que los días hábiles.

Durante marzo-mayo de 2020, con el inicio de la pandemia, el uso cayó abruptamente, generando outliers marcados en los boxplots. A partir de 2021 el uso se fue recuperando hasta estabilizarse en niveles similares a los previos a la pandemia.

Por estos dos factores (ciclo semanal y pandemia), las tres variables presentan distribuciones con sesgo hacia la izquierda, en vez de una forma simétrica.